Relatório de Regressão Linear: Qualidade do Vinho

Gabriel Braga Ledo Luduvico

RA: 22404076

Introdução

Este relatório apresenta os resultados de uma análise de regressão linear realizada no conjunto de dados “Wine Quality” do UCI Machine Learning Repository. O objetivo foi modelar a qualidade do vinho (variável de saída) com base em suas características físico-químicas (variáveis de entrada).

Metodologia

O conjunto de dados “Wine Quality” (ID 186) foi obtido do UCI Machine Learning Repository. Ele contém 6497 instâncias e 11 características físico-químicas, além da variável de qualidade. O dataset foi dividido em conjuntos de treino e teste (80% treino, 20% teste). Um modelo de regressão linear foi treinado usando o conjunto de treino e avaliado no conjunto de teste.

Resultados

Métricas de Avaliação

Após o treinamento e a avaliação do modelo, as seguintes métricas foram obtidas:

- **Erro Quadrático Médio (MSE):** 0.5467
- **Coeficiente de Determinação (R2):** 0.2598

O valor de R2 indica que aproximadamente 26% da variância na qualidade do vinho pode ser explicada pelas características físico-químicas incluídas no modelo. O MSE representa a média dos quadrados dos erros, ou seja, a diferença quadrática média entre os valores previstos e os valores reais.

Coeficientes do Modelo

Os coeficientes do modelo de regressão linear indicam a influência de cada característica físico-química na qualidade do vinho. Um coeficiente positivo sugere que um aumento na característica está associado a um aumento na qualidade, enquanto um coeficiente negativo sugere o oposto.

Característica	Coeficiente
sulphates	0.8084
pH	0.4828
alcohol	0.2707
fixed_acidity	0.0790
residual_sugar	0.0459
free_sulfur_dioxide	0.0070
total_sulfur_dioxide	-0.0027
citric_acid	-0.1438
chlorides	-0.3328
volatile_acidity	-1.3508
density	-58.9451

É importante notar que a `density` e a `volatile_acidity` possuem os maiores coeficientes em magnitude, indicando uma forte relação (negativa) com a qualidade do vinho.

Visualizações

Matriz de Correlação

A matriz de correlação abaixo ilustra as relações entre todas as variáveis do dataset. Cores mais quentes indicam correlação positiva, enquanto cores mais frias indicam correlação negativa.

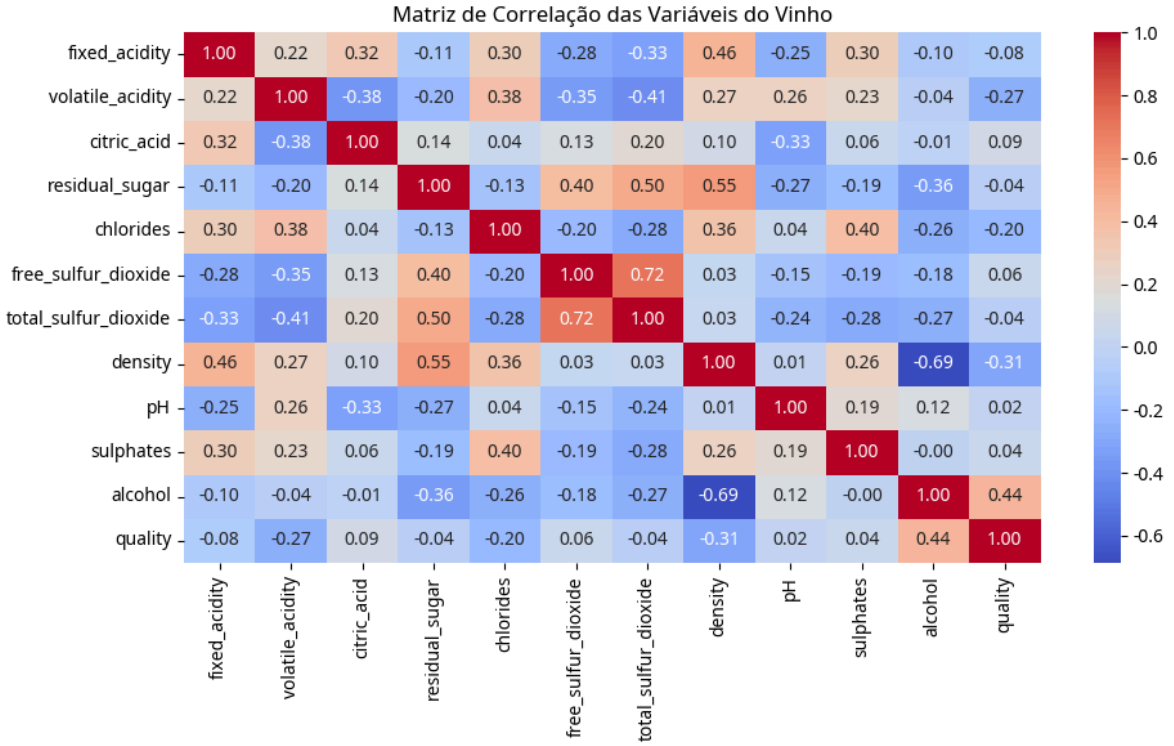

Resultados da Regressão

O gráfico de dispersão a seguir compara os valores de qualidade do vinho reais com os valores previstos pelo modelo de regressão linear. A linha diagonal representa onde os pontos estariam se as previsões fossem perfeitas.

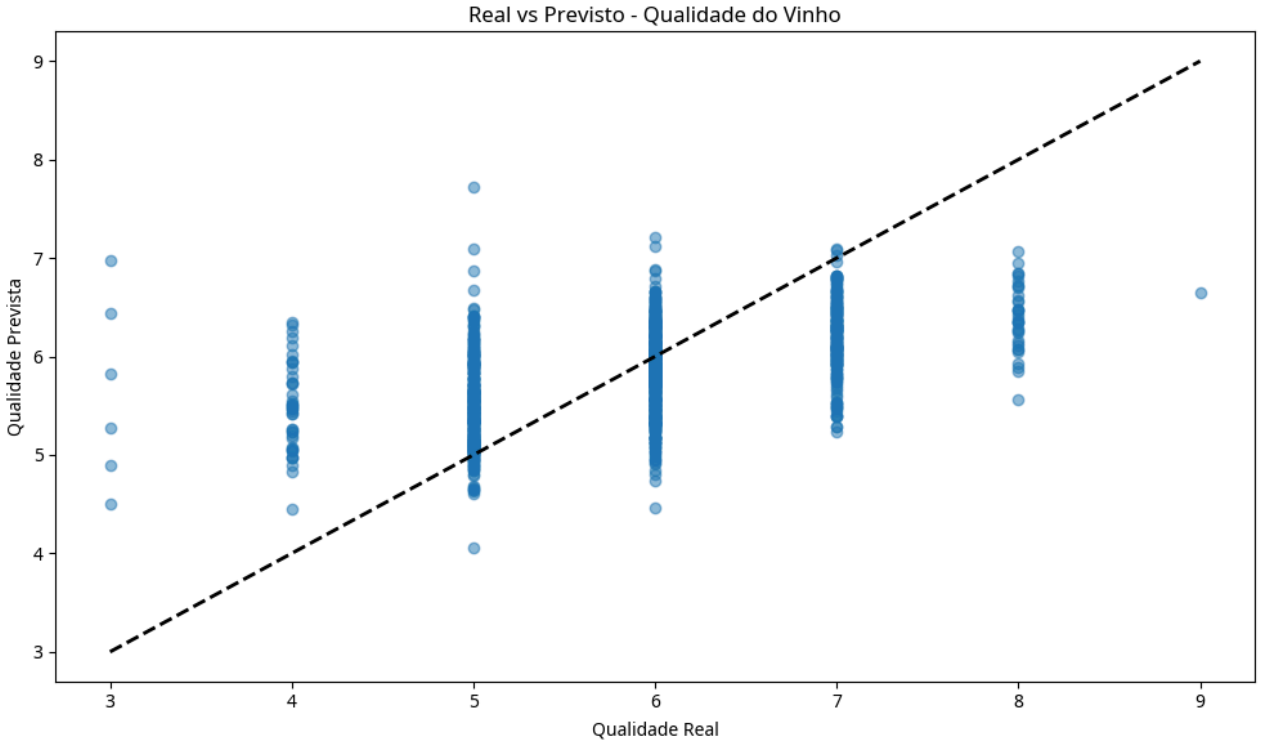

Conclusão

O modelo de regressão linear desenvolvido explica uma parte da variância na qualidade do vinho com base nas características físico-químicas. Embora o R2 de 0.2598 sugira que outros fatores não incluídos no modelo também influenciam a qualidade, a análise dos coeficientes fornece insights sobre quais características são mais relevantes. A `density` e a `volatile_acidity` mostraram ser as características com maior impacto negativo na qualidade percebida do vinho, enquanto `sulphates`, `pH` e `alcohol` tiveram um impacto positivo. Para melhorar a precisão do modelo, poderiam ser exploradas técnicas de engenharia de características, outros algoritmos de regressão ou a inclusão de variáveis adicionais, se disponíveis.

Referências